


# **Minicurso VI SAEM - Introdução ao Aprendizado de Máquina**



Victor Castro N. de Faria  
Doutorando em Pesquisa Operacional  
PPG-PO (ITA/Unifesp)

# Apresentação

## Formação

- Engenheiro mecânico (UFV, 2014 a julho de 2019)
- Membro da Equipe Skywards UFVoa (abril de 2015 a fevereiro de 2017) - Setor de estabilidade e controle
- Estagiário voluntário do Laboratório de Biocombustíveis (DEA - UFV, Março de 2017 a Maio de 2018)
- Bolsista de iniciação científica PIBIC-CNPq (Agosto 2017 a Julho 2018)
- Estagiário voluntário na Brno University of Technology (Janeiro de 2019 a Fevereiro de 2019)



Universidade Federal de Viçosa

# Apresentação

## Formação

- Atualmente doutorando em Pesquisa Operacional, na área de Ciência de Dados (programa de doutorado direto, Programa de Pós-Graduação em Pesquisa Operacional - ITA/Unifesp, São José dos Campos - SP).
- <https://www.unifesp.br/campus/sjc/ppgpo.html>



# Introdução

## O que é Aprendizado de Máquina (AM)?

- Primeiramente, Inteligência Artificial (IA) e Aprendizado de Máquina (AM) são a mesma coisa?
- IA, em linhas gerais, é um campo do conhecimento dedicado ao estudo de características de atividades de máquinas que são semelhantes a atividades executadas por seres humanos, seja no campo das ações ou no campo dos pensamentos. Agir e pensar como seres humanos ou de maneira "racional" (tomando as decisões "certas" dadas as informações disponíveis) são alguns dos objetivos da inteligência artificial.

# Introdução

## O que é IA, então? (Norvig e Russel, 2013)

- “A arte de criar máquinas que executam funções que exigem inteligência quando executadas por pessoas.” (Kurzweil, 1990);
- “IA... está relacionada a um desempenho inteligente de artefatos.” (Nilsson, 1998);
- “O estudo das computações que tornam possível perceber, raciocinar e agir.” (Winston, 1992);
- “O estudo das faculdades mentais pelo uso de modelos computacionais.” (Charniak e McDermott, 1985).

# Introdução

## O que é IA, então?

- Disciplinas compreendidas pela IA:
  - Processamento de linguagem natural (NLP);
  - Representação do conhecimento;
  - Raciocínio automatizado;
  - **Aprendizado de máquina (AM);**
  - Visão computacional;
  - Robótica.

# Introdução

## E o que é AM?

- “Diz-se que um programa de computador aprende pela experiência  $E$ , com respeito a algum tipo de tarefa  $T$  e desempenho (*performance*)  $P$ , se seu desempenho  $P$  nas tarefas em  $T$ , na forma medida por  $P$ , melhoram com a experiência  $E$ ” (Tom Mitchell, 1997).
- "Aprendizado de máquina é um campo de estudo que concede a computadores a habilidade de aprender sem serem explicitamente programados [para a tarefa em questão]" (Arthur Samuel, 1959).

# Introdução

## Exemplos de aplicações da AM

- Ferramentas de diagnóstico e prognóstico médico;
- Identificação de fraudes em transações financeiras;
- Identificação de perfil de consumidores;
- Sistemas de recomendação em plataformas de *e-commerce* e *streaming*;
- Videogames!
- Aspectos de problemas de otimização;

# Introdução

## E o que **NÃO É** AM?

- Métodos de busca:
  - Busca em largura;
  - Busca em profundidade;
  - Algoritmo A\*;
  - Árvores de busca (como o *Stockfish*).
- Jogadores artificiais de jogos eletrônicos cujas funções foram previamente programadas.



Fonte: chess.com

# Introdução

## E o que **NÃO É** AM?

- Métodos de otimização:
  - Heurísticas (são determinísticas);
  - Metaheurísticas (possuem componente aleatório embutido):
    - *Ant Colony Optimization* (ACO);
    - *Simulated Annealing* (SA);
    - *Iterated Local Search* (ILS);
    - *Variable Neighborhood Search* (VNS);
    - *Greedy Randomized Adaptive Search Procedure* (GRASP);
    - *Large Neighborhood Search* (LNS);
    - ***Genetic Algorithm* (GA).**

# Introdução

## E o que **NÃO É** AM?

- Apesar de não serem aprendizado, alguns tópicos podem ser associados ao aprendizado, como técnicas de otimização e metaheurísticas.

| Ponto do Crossover |   |   |   |   |   |   | Fitness |
|--------------------|---|---|---|---|---|---|---------|
| Pai 1              | 0 | 1 | 0 | 1 | 0 | 0 | 2       |
| Pai 2              | 0 | 1 | 1 | 0 | 0 | 1 | 3       |
| Prole 1            | 0 | 1 | 0 | 0 | 0 | 1 | 2       |
| Prole 2            | 0 | 1 | 1 | 1 | 0 | 0 | 3       |
| Depois da mutação  |   |   |   |   |   |   |         |
| Prole 1            | 0 | 1 | 1 | 0 | 0 | 0 | 2       |
| Prole 2            | 0 | 1 | 0 | 1 | 1 | 1 | 4       |

# Fundamentos

## Tipos de aprendizado

- **Aprendizado supervisionado (preditivo);**
  - **Classificação;**
  - **Regressão.**
- **Aprendizado não-supervisionado (descritivo);**
  - **Agrupamento;**
  - **Associação;**
  - **Sumarização.**
- **Aprendizado por reforço;**
- **Aprendizado semissupervisionado;**
- **Aprendizado ativo.**

## Algumas frases para recordar

- “Garbage in, garbage out”, atribuída ao técnico da IBM George Fuechsel (Wikipedia)
- “Tudo depende!”. Dependerá do contexto, da aplicação, da situação... tudo deve ter algum raciocínio por trás.

## Vieses de algoritmo como processos

- Viés de busca (Como o algoritmo encontra a melhor solução de modelo):
  - Maximização de margens (*Support Vector Machines*);
  - Minimização de medida de dissimilaridade (árvores de decisão ou agrupamento k-médias).
- Viés de representação (Como o algoritmo representa os modelos por ele obtidos):
  - Conjunto de regras;
  - Árvore de decisão;
  - Matrizes de pesos (redes neurais);
  - Equação de regressão linear ou logística.

# Fundamentos

## Sobre os dados

- Formato estruturado: tabela atributo-valor.

|    | A         | B         | C         | D         | E         | F           | G         | H              |
|----|-----------|-----------|-----------|-----------|-----------|-------------|-----------|----------------|
| 1  | Feature 1 | Feature 2 | Feature 3 | Feature 4 | Feature 5 | Feature 6   | Feature 7 | Target Feature |
| 2  | 0,75      | 0,91      | 0,26      | 08:00:00  | 1         | Brasil      | Grande    | 0,97           |
| 3  | 0,72      | 0,66      | 0,65      | 01:19:24  | 1         | Brasil      | Pequeno   | 0,81           |
| 4  | 0,48      | 0,40      | 0,07      | 08:25:46  | 1         | Polônia     | Pequeno   | 0,56           |
| 5  | 0,22      | 0,77      | 0,02      | 06:13:21  | 1         | EUA         | Médio     | 0,12           |
| 6  | 0,10      | 0,49      | 0,80      | 19:52:55  | 0         | Rep. Tcheca | Médio     | 0,25           |
| 7  | 0,34      | 0,55      | 0,84      | 10:52:39  | 1         | França      | Pequeno   | 0,99           |
| 8  | 0,82      | 0,29      | 0,52      | 16:28:25  | 0         | Áustria     | Grande    | 0,70           |
| 9  | 0,15      | 0,02      | 0,86      | 03:05:08  | 0         | Áustria     | Pequeno   | 0,86           |
| 10 | 0,10      | 0,94      | 0,09      | 15:43:35  | 1         | Alemanha    | Grande    | 0,21           |
| 11 | 0,73      | 0,45      | 0,88      | 20:49:21  | 1         | França      | Grande    | 0,50           |
| 12 | 0,85      | 0,63      | 0,85      | 16:33:18  | 0         | EUA         | Médio     | 0,11           |
| 13 | 0,36      | 0,41      | 0,56      | 13:23:33  | 1         | Polônia     | Pequeno   | 0,15           |
| 14 | 0,26      | 0,79      | 0,92      | 07:34:24  | 1         | Brasil      | Pequeno   | 0,46           |
| 15 | 0,36      | 0,91      | 0,88      | 18:04:56  | 1         | Rep. Tcheca | Médio     | 0,38           |

# Fundamentos

## Metadados

- Uma tabela explicando os atributos envolvidos nos dados fornecidos (Exemplo dos Microdados do ENEM).


| DADOS DA ESCOLA        |                                          |   |                                    |     |              |
|------------------------|------------------------------------------|---|------------------------------------|-----|--------------|
| CO_MUNICIPIO_ESC       | Código do município da escola            |   |                                    | 7   | Numérica     |
|                        | 1º dígito: Região                        |   |                                    |     |              |
|                        | 1º e 2º dígitos: UF                      |   |                                    |     |              |
|                        | 3º, 4º, 5º e 6º dígitos: Município       |   |                                    |     |              |
|                        | 7º dígito: dígito verificador            |   |                                    |     |              |
| NO_MUNICIPIO_ESC       | Nome do município da escola              |   |                                    | 150 | Alfanumérica |
| CO_UF_ESC              | Código da Unidade da Federação da escola |   |                                    | 2   | Numérica     |
| SG_UF_ESC              | Sigla da Unidade da Federação da escola  |   |                                    | 2   | Alfanumérica |
| TP_DEPENDENCIA_ADM_ESC | Dependência administrativa (Escola)      | 1 | Federal                            | 1   | Numérica     |
|                        |                                          | 2 | Estadual                           |     |              |
|                        |                                          | 3 | Municipal                          |     |              |
|                        |                                          | 4 | Privada                            |     |              |
| TP_LOCALIZACAO_ESC     | Localização (Escola)                     | 1 | Urbana                             | 1   | Numérica     |
|                        |                                          | 2 | Rural                              |     |              |
| TP_SIT_FUNC_ESC        | Situação de funcionamento (Escola)       | 1 | Em atividade                       | 1   | Numérica     |
|                        |                                          | 2 | Paralisada                         |     |              |
|                        |                                          | 3 | Extinta                            |     |              |
|                        |                                          | 4 | Escola extinta em anos anteriores. |     |              |

# Fundamentos

## Pipeline típico de AM

- Processo típico pelo qual modelos de AM são construídos e treinados.
- Podem existir etapas iterativas e retorno a etapas anteriores!

Obtenção dos  
dados



Análise  
exploratória  
de dados



Pré-  
processamento  
de dados



Treinamento  
do(s) modelo(s)  
de AM



Validação do(s)  
modelo(s)



Implantação  
(*Deployment*)

# Que dados serão usados aqui?

## Wine dataset (Biblioteca do *scikit-learn*)

- A base de dados contém os atributos:
  - 1) Alcohol (Álcool)
  - 2) Malic acid (Ácido málico)
  - 3) Ash (Cinzas)
  - 4) Alkalinity of ash (Alcalinidade das cinzas)
  - 5) Magnesium (Magnésio)
  - 6) Total phenols (Fenóis totais)
  - 7) Flavanoids (Flavonóides)
  - 8) Nonflavanoid phenols (Fenóis não flavonóides)
  - 9) Proanthocyanins (Proantocianinas - pigmentos)
  - 10) Color intensity (intensidade da cor)
  - 11) Hue (matiz)
  - 12) OD280/OD315 of diluted wines (razão entre as densidades ópticas a 280 nm e 315 nm do produto diluído)
  - 13) Proline (Prolina - aminoácido)

# Que dados serão usados aqui?

## **Wine dataset (Biblioteca do *scikit-learn*)**

Detentores originais da base de dados:

Forina, M. et al, PARVUS - An Extendible Package for Data Exploration, Classification and Correlation. Institute of Pharmaceutical and Food Analysis and Technologies, Via Brigata Salerno, 16147 Genoa, Italy.

Para maiores detalhes: <https://archive.ics.uci.edu/ml/datasets/wine>

## Análise exploratória de dados

- Primeira etapa do *pipeline* do aprendizado, envolvendo:
  - Caracterização de dados;
  - Medidas estatísticas envolvendo cada um dos atributos:
    - Média, mediana e moda;
    - Variância e desvio padrão;
    - Quartis (ou percentis, se assim desejar).
  - Identificação de fenômenos nos dados:
    - *Outliers*;
    - Ruídos.

## Análise exploratória de dados

- Caracterização de dados quanto a sua escala e seu tipo:
  - Qualitativos, simbólicos ou categóricos:
    - Escala nominal (Não importa se há uma “ordem”)
    - Escala ordinal (Há uma “ordem” quanto aos valores)
  - Quantitativos ou numéricos:
    - Tipo discreto vs tipo contínuo;
    - Escala intervalar (Valores só fazem sentido em um contexto de intervalo de medidas, operações de multiplicação e divisão não fazem sentido e não existe zero absoluto).
    - Escala racional (Existe zero absoluto, pode multiplicar e dividir).

# Fundamentos

## Análise exploratória de dados

- Caracterização de dados:
  - Qualitativos:
    - Escala nominal: Feature 6
    - Escala ordinal: Feature 7
  - Quantitativos:
    - Discreto: Feature 5
    - Contínuo: Feature 3;
    - Escala intervalar: Feature 4
    - Escala racional: Feature 3

| Feature 3 | Feature 4 | Feature 5 | Feature 6   | Feature 7 | Target Feature |
|-----------|-----------|-----------|-------------|-----------|----------------|
| 0,26      | 08:00:00  | 1         | Brasil      | Grande    | 0,97           |
| 0,65      | 01:19:24  | 1         | Brasil      | Pequeno   | 0,81           |
| 0,07      | 08:25:46  | 1         | Polônia     | Pequeno   | 0,56           |
| 0,02      | 06:13:21  | 1         | EUA         | Médio     | 0,12           |
| 0,80      | 19:52:55  | 0         | Rep. Tcheca | Médio     | 0,25           |
| 0,84      | 10:52:39  | 1         | França      | Pequeno   | 0,99           |
| 0,52      | 16:28:25  | 0         | Áustria     | Grande    | 0,70           |
| 0,86      | 03:05:08  | 0         | Áustria     | Pequeno   | 0,86           |
| 0,09      | 15:43:35  | 1         | Alemanha    | Grande    | 0,21           |
| 0,88      | 20:49:21  | 1         | França      | Grande    | 0,50           |
| 0,85      | 16:33:18  | 0         | EUA         | Médio     | 0,11           |
| 0,56      | 13:23:33  | 1         | Polônia     | Pequeno   | 0,15           |
| 0,92      | 07:34:24  | 1         | Brasil      | Pequeno   | 0,46           |
| 0,88      | 18:04:56  | 1         | Rep. Tcheca | Médio     | 0,38           |

## Análise exploratória de dados

- *Outliers:*
  - São dados que se distanciam da maioria das observações quanto a um ou mais valores de atributos.
  - Podem causar problemas em processos de regressão;
  - Podem ser detectados com medidas estatísticas, como mediana e quartis ou percentis;
  - Proposta de identificação de *outliers* por Tukey (1977): *Outliers* são aqueles dados que estão mais distantes do primeiro quartil menos 1.5 vezes o intervalo interquartil (IQR) ou do terceiro quartil mais  $1.5 \times \text{IQR}$

# Fundamentos

## Análise exploratória de dados

```
In [176]: 1 import numpy as np
          2 import pandas as pd
          3 from sklearn.datasets import load_wine
          4 import matplotlib.pyplot as plt
          5
          6 data_wine = load_wine() # Retorna como dicionário de arrays
          7 features = data_wine.feature_names
          8 X_data_wine = pd.DataFrame(data_wine.data, columns = features)
          9 y_data_wine = pd.DataFrame(data_wine.target, columns = ['target'])
```

```
In [178]: 1 #data_wine_features.columns = features
          2 X_data_wine.head()
```

Out[178]:

|   | alcohol | malic_acid | ash  | alcalinity_of_ash | magnesium | total_phenols | flavanoids | nonflavanoid_phenols | proanthocyanins | color_intensity | hue  | od280/od315_ |
|---|---------|------------|------|-------------------|-----------|---------------|------------|----------------------|-----------------|-----------------|------|--------------|
| 0 | 14.23   | 1.71       | 2.43 | 15.6              | 127.0     | 2.80          | 3.06       | 0.28                 | 2.29            | 5.64            | 1.04 |              |
| 1 | 13.20   | 1.78       | 2.14 | 11.2              | 100.0     | 2.65          | 2.76       | 0.26                 | 1.28            | 4.38            | 1.05 |              |
| 2 | 13.16   | 2.36       | 2.67 | 18.6              | 101.0     | 2.80          | 3.24       | 0.30                 | 2.81            | 5.68            | 1.03 |              |
| 3 | 14.37   | 1.95       | 2.50 | 16.8              | 113.0     | 3.85          | 3.49       | 0.24                 | 2.18            | 7.80            | 0.86 |              |
| 4 | 13.24   | 2.59       | 2.87 | 21.0              | 118.0     | 2.80          | 2.69       | 0.39                 | 1.82            | 4.32            | 1.04 |              |

< >

# Fundamentos

## Análise exploratória de dados

```
In [180]: 1 X_data_wine.describe()
```


```
Out[180]:
```

|       | alcohol    | malic_acid | ash        | alcalinity_of_ash | magnesium  |
|-------|------------|------------|------------|-------------------|------------|
| count | 178.000000 | 178.000000 | 178.000000 | 178.000000        | 178.000000 |
| mean  | 13.000618  | 2.336348   | 2.366517   | 19.494944         | 99.741573  |
| std   | 0.811827   | 1.117146   | 0.274344   | 3.339564          | 14.282484  |
| min   | 11.030000  | 0.740000   | 1.360000   | 10.600000         | 70.000000  |
| 25%   | 12.362500  | 1.602500   | 2.210000   | 17.200000         | 88.000000  |
| 50%   | 13.050000  | 1.865000   | 2.360000   | 19.500000         | 98.000000  |
| 75%   | 13.677500  | 3.082500   | 2.557500   | 21.500000         | 107.000000 |
| max   | 14.830000  | 5.800000   | 3.230000   | 30.000000         | 162.000000 |

<

## Análise exploratória de dados



```
In [246]: 1 y_data_wine.hist();
```



# Fundamentos

## Análise exploratória de dados

- Identificando *Outliers* (TUKEY, John W. et al. Exploratory data analysis. 1977)



## Análise exploratória de dados

- Ruídos:
  - São valores oriundos de erro aleatório, erro de imputação (automático ou humano), erro de instrumentação, entre outras causas.
  - As observações com dados ruidosos não se identificam com a distribuição do restante dos dados.
  - Podem levar a algum *overfitting* do modelo.
- Exemplos de ruídos:
  - Detecção de sinais vibratórios por excesso de sensibilidade ou amostragem;
  - Temperaturas acima de 100 graus Celsius em ambientes de campo;
  - Entradas incoerentes de dados de pessoas em bases para fins de saúde.

## Pré-processamento de dados

- Aqui cabem processos que visam lidar com os dados antes de submetê-los ao aprendizado, tais como:
  - Redução de dimensionalidade;
  - Tratamento de ruídos, valores faltantes ou inconsistências;
  - Investigação de observações redundantes;
  - Transformação de dados por meio de *encoding*, escalonamento ou padronização;
  - Balanceamento de observações com base na classe majoritária.

## Pré-processamento de dados

- Redução de dimensionalidade visa diminuir o número de atributos envolvidos para atender a alguns requisitos, tais como:
  - Prevenir a “maldição da dimensionalidade”, descrito primeiro como problema encontrado em programação dinâmica por Richard Bellmann (*Dynamic Programming*, 1957);
  - Eliminar atributos correlacionados, redundantes ou inadequados para o aprendizado;
  - Criar novos atributos (*Feature Engineering* ou *Principal Component Analysis*);

# Fundamentos

## Pré-processamento de dados - Normalização


- Escalonamento (por amplitude):  
Comportar os valores de dados em um intervalo definido, tipicamente entre 0 e 1.
- Pode ter limites personalizados para atributos mais ou menos importantes do seu conjunto de dados, pois as variações dos dados podem ser objeto de preservação.
- Padronização (por distribuição):  
Fazer com que os dados tenham média 1 e desvio padrão 0.
- Costuma lidar melhor com *outliers*.

$$x_{novo} = \frac{x_{atual} - x_{menor}}{x_{maior} - x_{menor}} * (lim_{max} - lim_{min})$$

$$x_{novo} = \frac{x_{atual} - \mu_{atributo}}{\sigma_{atributo}}$$



# Fundamentos

## Exemplo de transformação de dados



# Fundamentos

## Exemplo de transformação de dados



# Transformação de dados

## Lembrete importante

Quando aplicado ao aprendizado, é importante lembrar que todas as transformações numéricas devem ser referentes aos dados de **TREINAMENTO!!!!!!**

Quaisquer transformações nos dados de teste devem usar média e desvio padrão ou valor mínimo e valor máximo dos atributos dos dados de **treinamento!!**

# Transformação de dados

## Escalonamento de dados

In [186]:

```
1 from sklearn.preprocessing import MinMaxScaler
2
3 scaler = MinMaxScaler(feature_range=(0, 1))
4 x_scaled = scaler.fit_transform(X_data_wine)
5
6 x_scaled = pd.DataFrame(x_scaled, columns = X_data_wine.columns)
7 x_scaled.head()
```

Out[186]:

|   | alcohol  | malic_acid | ash      | alcalinity_of_ash | magnesium | total_phenols | flavanoids |
|---|----------|------------|----------|-------------------|-----------|---------------|------------|
| 0 | 0.842105 | 0.191700   | 0.572193 | 0.257732          | 0.619565  | 0.627586      | 0.573840   |
| 1 | 0.571053 | 0.205534   | 0.417112 | 0.030928          | 0.326087  | 0.575862      | 0.510549   |
| 2 | 0.560526 | 0.320158   | 0.700535 | 0.412371          | 0.336957  | 0.627586      | 0.611814   |
| 3 | 0.878947 | 0.239130   | 0.609626 | 0.319588          | 0.467391  | 0.989655      | 0.664557   |
| 4 | 0.581579 | 0.365613   | 0.807487 | 0.536082          | 0.521739  | 0.627586      | 0.495781   |

<

# Transformação de dados

## Escalonamento de dados

In [187]: 1 x\_scaled.describe()

Out[187]:

|       | alcohol    | malic_acid | ash        | alcalinity_of_ash |
|-------|------------|------------|------------|-------------------|
| count | 178.000000 | 178.000000 | 178.000000 | 178.000000        |
| mean  | 0.518584   | 0.315484   | 0.538244   | 0.458502          |
| std   | 0.213639   | 0.220780   | 0.146708   | 0.172142          |
| min   | 0.000000   | 0.000000   | 0.000000   | 0.000000          |
| 25%   | 0.350658   | 0.170455   | 0.454545   | 0.340206          |
| 50%   | 0.531579   | 0.222332   | 0.534759   | 0.458763          |
| 75%   | 0.696711   | 0.462945   | 0.640374   | 0.561856          |
| max   | 1.000000   | 1.000000   | 1.000000   | 1.000000          |

<

# Transformação de dados

## Normalização de dados

In [188]:

```
1 from sklearn.preprocessing import StandardScaler
2
3 scaler = StandardScaler()
4 x_standardized = scaler.fit_transform(X_data_wine)
5
6 x_standardized = pd.DataFrame(x_standardized, columns = X_data_wine.columns)
7 x_standardized.head()
```

Out[188]:

|   | alcohol  | malic_acid | ash       | alcalinity_of_ash | magnesium | total_phenols | flavanoids | nonflavanoid_phenols |
|---|----------|------------|-----------|-------------------|-----------|---------------|------------|----------------------|
| 0 | 1.518613 | -0.562250  | 0.232053  | -1.169593         | 1.913905  | 0.808997      | 1.034819   | -0.659563            |
| 1 | 0.246290 | -0.499413  | -0.827996 | -2.490847         | 0.018145  | 0.568648      | 0.733629   | -0.820719            |
| 2 | 0.196879 | 0.021231   | 1.109334  | -0.268738         | 0.088358  | 0.808997      | 1.215533   | -0.498407            |
| 3 | 1.691550 | -0.346811  | 0.487926  | -0.809251         | 0.930918  | 2.491446      | 1.466525   | -0.981875            |
| 4 | 0.295700 | 0.227694   | 1.840403  | 0.451946          | 1.281985  | 0.808997      | 0.663351   | 0.226796             |

# Transformação de dados

## Normalização de dados

```
In [189]: 1 x_standardized.describe().round(decimals = 3)
```

```
Out[189]:
```

|       | alcohol | malic_acid | ash     | alcalinity_of_ash | magnesium | t |
|-------|---------|------------|---------|-------------------|-----------|---|
| count | 178.000 | 178.000    | 178.000 | 178.000           | 178.000   |   |
| mean  | 0.000   | 0.000      | -0.000  | -0.000            | -0.000    |   |
| std   | 1.003   | 1.003      | 1.003   | 1.003             | 1.003     |   |
| min   | -2.434  | -1.433     | -3.679  | -2.671            | -2.088    |   |
| 25%   | -0.788  | -0.659     | -0.572  | -0.689            | -0.824    |   |
| 50%   | 0.061   | -0.423     | -0.024  | 0.002             | -0.122    |   |
| 75%   | 0.836   | 0.670      | 0.698   | 0.602             | 0.510     |   |
| max   | 2.260   | 3.109      | 3.156   | 3.155             | 4.371     |   |

<

# Fundamentos

## Pré-processamento de dados

- Dados qualitativos precisam ser transformados, uma vez que diversos algoritmos lidam apenas com dados numéricos.
- Duas transformações assim são o *one-hot encoding* (que cria mais atributos) e o mapeamento para números (*label encoding*).
- Atenção às métricas de distâncias!!!

| Dados originais |
|-----------------|
| Azul            |
| Verde           |
| Vermelho        |
| Vermelho        |
| Azul            |

| is_blue | is_green | is_red |
|---------|----------|--------|
| 1       | 0        | 0      |
| 0       | 1        | 0      |
| 0       | 0        | 1      |
| 0       | 0        | 1      |
| 1       | 0        | 0      |

| cor_codificado |
|----------------|
| 0              |
| 1              |
| 2              |
| 2              |
| 0              |

# Modelos de Aprendizado

## Os modelos tratados neste minicurso

- Aprendizado supervisionado:
  - Precisa de um atributo alvo (ou atributo meta) além dos demais atributos dos dados.
  - Tem como objetivo prever o valor ou classe correspondente do atributo alvo.
- Aprendizado não-supervisionado:
  - Não necessita de um atributo alvo, se vale apenas dos atributos de entrada.
  - Útil para identificar padrões entre os atributos ou agrupamentos de observações.

# Modelos de Aprendizado

## Aprendizado supervisionado

- Modelos de AM supervisionado se valem de separação de dados em dois conjuntos:
  - Treino (em que o algoritmo é “treinado” ou “ajustado”).
  - Teste (em que o algoritmo é avaliado sob exemplos).
- Idealmente, os conjuntos de treino e teste são disjuntos (não há elementos em comum entre si).

# Modelos de Aprendizado

# Aprendizado supervisionado


[illegible]

# Modelos de Aprendizado

## Regressão linear!

- Tem como objetivo ajustar uma equação de reta aos dados, que é uma combinação linear dos valores dos atributos de cada observação.
- Aqui pode caber alguns recursos de *Feature Engineering*, como transformação por algumas funções (potenciação, radiciação, logaritmos...).

$$y = \beta_0 + \sum \beta_i x_i$$




# Modelos de Aprendizado

## Regressão linear!

- E se fizermos de  $x^2$  a variável independente?



$$y = \beta_0 + \sum \beta_i x_i$$



# Modelos de Aprendizado

## O fenômeno do *Overfitting*


- É um fenômeno em que o modelo está ajustado aos dados de maneira a minimizar a métrica de erro, mas com pouco poder de generalização.



# Modelos de Aprendizado

## O fenômeno do *Overfitting*

- Pode surgir da adoção de um modelo complexo demais!



# Modelos de Aprendizado

## O fenômeno do *Overfitting*

- Uma estratégia para evitar o fenômeno é o uso de regularização, em que um termo “pune” um sobreajuste na função de erro (ou de custo, ou de perda) do algoritmo.
- A estratégia é mais usada em modelos mais complexos. O exemplo com a regressão linear é apenas para contextualização!!

- Sejam, para fins de exemplos:

- $f$  a função do seu modelo linear;
- $R(f)$  uma função de regularização.


$$RSS = \sum_{i=1}^n (Y_i - f(x_i))^2 + \lambda * R(f)$$

# Modelos de Aprendizado

## Regressão logística

- Tem como resultado um valor de probabilidade de uma observação pertencer a uma das classes de um problema binário (apesar de ser um problema com atributo alvo categórico, é essencialmente um problema de regressão).
- Com o estabelecimento de um limiar de probabilidade, é possível transformar o modelo para um modelo de classificação.

(JAMES et al., 2013)



# Modelos de Aprendizado

## Regressão logística

- E como lidar com mais de uma classe?
- (Introdução à ideia de modelos múltiplos preditivos).

| Classes | One-Against-All |            |            |
|---------|-----------------|------------|------------|
|         | A vs todos      | B vs todos | C vs todos |
| A       | 1               | -1         | -1         |
| B       | -1              | 1          | -1         |
| C       | -1              | -1         | 1          |

| One-Against-One |        |        |
|-----------------|--------|--------|
| A vs B          | A vs C | B vs C |
| 1               | 1      | 0      |
| -1              | 0      | 1      |
| 0               | -1     | -1     |

LORENA, Ana Carolina; DE CARVALHO, André CPLF; GAMA, João MP. A review on the combination of binary classifiers in multiclass problems. **Artificial Intelligence Review**, v. 30, n. 1, p. 19-37, 2008.

# Modelos de Aprendizado

## E como ajustar os parâmetros?


- *Gradient Descent*: Heurística iterativa usada para atualização de parâmetros baseado na taxa de variação da função de custo em relação a cada um dos parâmetros.
- Depende de uma taxa de aprendizado  $\alpha$  bem ajustada - pode cair em mínimos locais, divergir ou ter convergência lenta.
- Seja um parâmetro  $\beta$  do modelo e  $n$  o número da atual iteração do treinamento.

$$\beta_{n+1} = \beta_n - \alpha * \frac{\partial \text{Custo}}{\partial \beta}$$

# Modelos de Aprendizado

## E como ajustar os parâmetros?

- <https://www.ibm.com/cloud/learn/gradient-descent>



# Modelos de Aprendizado


## k vizinhos mais próximos (k-Nearest Neighbors)

- Dados são comparados com os seus  $k$  vizinhos mais próximos dentro do espaço de atributos, de maneira que os vizinhos votam quanto ao valor da variável meta por voto majoritário (pode ter ponderações quanto à importância de cada vizinho).
- A proximidade depende da métrica de distância utilizada:
  - Manhattan: soma das diferenças entre os valores dos atributos;
  - Euclidiana: Teorema de Pitágoras em espaços n-dimensionais;
  - Hamming: Distância entre atributos qualitativos - depende do *encoding*;
  - Chebyshev: Máximo da diferença absoluta em coordenadas.

# Modelos de Aprendizado

## k vizinhos mais próximos (k-Nearest Neighbors)

- <https://www.ibm.com/topics/knn#:~:text=The%20k-nearest%20neighbors%20algorithm%2C%20also%20known%20as%20KNN%20or,of%20an%20individual%20data%20point.>



# Modelos de Aprendizado

## k vizinhos mais próximos (k-Nearest Neighbors)

In [34]:

```
1  # Aplicação de k-Nearest Neighbors
2  # Uso dos dados de vinho apresentados
3
4  from sklearn import neighbors
5  clf = neighbors.KNeighborsClassifier(3, weights = 'uniform')
6  clf.fit(X_train, y_train.values.ravel())
7
8  y_predict = clf.predict(X_test)
9  |
10
11 classification_metrics(clf, X_test, y_test, cmap='Blues')
```

# Modelos de Aprendizado


## k vizinhos mais próximos (k-Nearest Neighbors)

Aqui aparecem algumas métricas de classificação:

- Acurácia: Proporção de todos os exemplos corretamente classificados  $(VP + VN)/n$
- Precisão: Proporção de exemplos classificados como verdadeiramente positivos dentre todos **classificados como positivos**  $VP/(VP + FP)$
- Revocação: Proporção de exemplos classificados como verdadeiramente positivos dentre todos **os exemplos positivos**  $VP/(VP + FN)$

Modelo: KNeighborsClassifier

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.71      | 0.71   | 0.71     | 7       |
| 1            | 0.67      | 0.57   | 0.62     | 7       |
| 2            | 0.20      | 0.25   | 0.22     | 4       |
| accuracy     |           |        | 0.56     | 18      |
| macro avg    | 0.53      | 0.51   | 0.52     | 18      |
| weighted avg | 0.58      | 0.56   | 0.57     | 18      |



# Modelos de Aprendizado

## Árvore de decisão

- Método de aprendizagem que divide os dados de acordo com regras de decisão (testes) com saídas binárias, de maneira a elaborar hipóteses simples que reduzem a função de custo do conjunto de dados.
- Cada nó da árvore faz testes baseado em um único atributo, e seu valor de limiar é baseado em alguma medida de separabilidade entre os dados:
  - Entropia (medida de aleatoriedade do atributo alvo);
  - Índice de Gini (medida de homogeneidade quanto ao atributo alvo);
  - Erro de classificação.
- É um método muito sensível a mudanças no conjunto de dados.


# Modelos de Aprendizado

## Árvore de decisão

```
In [36]: 1 from sklearn.tree import DecisionTreeClassifier, plot_tree
2
3 dt = DecisionTreeClassifier(criterion='entropy')
4 dt.fit(X_train,y_train);
5 classification_metrics(dt, X_test, y_test, 'Oranges')
6
7 plt.figure(figsize = (16, 7))
8 plot_tree(dt, max_depth = 3, fontsize = 13, filled=True, feature_names=X_train.columns);
9 plt.show()
```


Modelo: DecisionTreeClassifier

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 1.00      | 1.00   | 1.00     | 7       |
| 1            | 1.00      | 1.00   | 1.00     | 7       |
| 2            | 1.00      | 1.00   | 1.00     | 4       |
| accuracy     |           |        | 1.00     | 18      |
| macro avg    | 1.00      | 1.00   | 1.00     | 18      |
| weighted avg | 1.00      | 1.00   | 1.00     | 18      |



# Modelos de Aprendizizado

## Árvore de decisão



# Modelos de Aprendizado

## Variação: Random Forest Classifier


- Em vez de uma única árvore, várias árvores são treinadas com diferentes subconjuntos dos dados de teste e elas formam um comitê de classificação.
- Cada modelo individual é menos forte que uma árvore singular sobre toda a base, mas o comitê possui maior poder de generalização que a árvore singular.

In [130]:

```
1 from sklearn.ensemble import RandomForestClassifier
2 rand_forest = RandomForestClassifier(criterion='entropy', random_state=0, n_jobs=-1)
3 rand_forest.fit(X_train, y_train)
4 classification_metrics(rand_forest, X_test, y_test, 'mako')
```

Modelo: RandomForestClassifier

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 1.00      | 1.00   | 1.00     | 7       |
| 1            | 1.00      | 1.00   | 1.00     | 7       |
| 2            | 1.00      | 1.00   | 1.00     | 4       |
| accuracy     |           |        | 1.00     | 18      |
| macro avg    | 1.00      | 1.00   | 1.00     | 18      |
| weighted avg | 1.00      | 1.00   | 1.00     | 18      |



# Modelos de Aprendizado

## Naïve-Bayes (Bayes Ingênuo)

- O método retorna uma probabilidade de um exemplo pertencer a uma das classes do atributo alvo, dadas as análises sobre a frequência de observação de valores de atributos dado o atributo alvo.
- O termo “ingênuo” vem da premissa de que os atributos são independentes entre si, dada a classe (teoria de probabilidade conjunta).
- Com atributos quantitativos, deve-se primeiro transformá-los de acordo com alguma distribuição de probabilidades ou discretizá-los.
- Hipótese *Maximum A Posteriori* (MAP): A classe que receber o maior valor de probabilidade deve ser elencada ao exemplo de teste.


# Modelos de Aprendizado

## Naïve-Bayes (Bayes Ingênuo)

```
In [134]: 1 # Implementação do classificador Naïve-Bayes,  
2 # assumindo que os dados de entrada  
3 # obedecem uma distribuição normal  
4  
5 from sklearn.naive_bayes import GaussianNB  
6  
7 gnb = GaussianNB()  
8 gnb.fit(X_train, y_train)  
9 y_pred = gnb.predict(X_test)  
10 classification_metrics(gnb, X_test, y_test, 'magma')
```

Modelo: GaussianNB

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 1.00      | 1.00   | 1.00     | 7       |
| 1            | 1.00      | 1.00   | 1.00     | 7       |
| 2            | 1.00      | 1.00   | 1.00     | 4       |
| accuracy     |           |        | 1.00     | 18      |
| macro avg    | 1.00      | 1.00   | 1.00     | 18      |
| weighted avg | 1.00      | 1.00   | 1.00     | 18      |




# Modelos de Aprendizado

## Redes Neurais

- É um modelo baseado no funcionamento do neurônio humano, em que uma combinação linear dos valores de atributos (mais um termo de viés, ou “bias”) é submetido a uma função que pondera a ativação ou desativação do neurônio.
- O treinamento é feito de maneira sequencial, em que os pesos da rede são atualizados a cada novo exemplo a ela apresentado (há variações).
- A base de dados pode ser apresentada mais de uma vez ao algoritmo (em mais de uma “época”).
- A saída do algoritmo pode variar de acordo com a arquitetura, mas tipicamente é um vetor correspondente às probabilidades de cada exemplo pertencer à classe correspondente.

# Modelos de Aprendizado

## Redes Neurais




# Modelos de Aprendizado

## Redes Neurais - Funções de ativação

JAYAWARDANA, JK Rahul; BANDARANAYAKE, T. Sameera. Analysis of optimizing neural networks and artificial intelligent models for guidance, control, and navigation systems. International Research Journal of Modernization in Engineering, Technology and Science, v. 3, n. 3, p. 743-759, 2021.


**Sigmoid**

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



**tanh**

$$\tanh(x)$$




**ReLU**

$$\max(0, x)$$



**Leaky ReLU**

$$\max(0.1x, x)$$



**Maxout**

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$


**ELU**

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



# Modelos de Aprendizizado

## Redes Neurais



# Modelos de Aprendizado

## Redes Neurais

- Pontos importantes para discussão:
  - Lidando com dados não estruturados;
  - Arquitetura da rede;
  - Como os pesos serão ajustados (*backpropagation* ou metaheurísticas);
  - Escolha das funções de ativação;
  - Uso de outros recursos (convolução, recorrência...);
  - Cuidado com saturação da rede;
  - Inicialização de pesos e possível desligamento de conexões.

Para experimentar vários recursos: <https://playground.tensorflow.org/>

# Modelos de Aprendizado

## **Aprendizado não supervisionado**


- Não há a necessidade de haver, na base de dados, um atributo alvo. Informações são obtidas de dados sem rótulos associados.
- Objetiva-se encontrar descrições acerca dos dados, seja a identificação de agrupamentos, associações ou sumarização.

# Modelos de Aprendizado

## Agrupamento k-médias (k-means clustering)

- Dado um conjunto de dados, objetiva-se associá-los a  $k$  agrupamentos (ou *clusters*, tipicamente disjuntos) de maneira a minimizar a soma das distâncias desses pontos ao centroide do agrupamento.
- O número de agrupamentos pode não ser conhecido a princípio.
- O método pode requerer múltiplas execuções em função da possibilidade de atingir mínimos locais devido à inicialização.

<https://towardsdatascience.com/understanding-k-means-clustering-in-machine-learning-6a6e67336aa1>



# Modelos de Aprendizado



## Algoritmo hierárquico

- O algoritmo busca agrupamentos de pontos encadeados (próximos entre si), valendo-se de métricas de integração (*linkage metrics*) (FACELI et al, 2021) e obtendo, como saída, um dendograma de hierarquias de agrupamentos.
- “Nesses algoritmos, os dados são manipulados de forma que, se dois objetos são agrupados/divididos em algum nível, nos níveis mais altos eles continuam fazendo parte do mesmo grupo, produzindo uma hierarquia de *clusters*”. (FACELI et al, 2021).
- O algoritmo é capaz de identificar agrupamentos difíceis de identificar com K-médias.

# Modelos de Aprendizado

## Algoritmo hierárquico


<https://towardsdatascience.com/hierarchical-clustering-explained-e59b13846da8>



# Modelos de Aprendizado

## Algoritmo hierárquico

<https://towardsdatascience.com/hierarchical-clustering-explained-e59b13846da8>



# Modelos de Aprendizado

## Algoritmo apriori

- Algoritmo elaborado para identificar conjuntos de itens e regras de associação entre observações de uma base de dados.
- Diferentes subconjuntos dos itens são gerados e métodos de busca são empregados para obter regras de associação com valores de suporte.
- Aplicação em descrição de perfis e padrões de consumo de produtos em mercados.

AGRAWAL, Rakesh et al. Fast algorithms for mining association rules. In: Proc. 20th int. conf. very large data bases, VLDB. 1994. p. 487-499.

# Outros tópicos

## E aí? Acabou?

- Alguns algoritmos ficaram de fora da discussão, tais como:
  - *Support Vector Machines*, método baseado em maximização de margens;
  - *Linear discriminant Analysis* e *Quadratic Discriminant Analysis*;
  - *Self-Organizing Maps*;
- Houveram outros tópicos que ficaram de fora também!
  - Aprendizado contínuo;
  - Sistemas de recomendação;
  - Aprendizado profundo (*Deep Learning*);
  - Avaliação de modelos preditivos e descritivos;
  - Testes de hipótese, amostragem, *cross validation*, entre outros.
  - *Large Language Models*, modelos *GPT*, *DeepSeek*, IAs generativas...

# Conclusões

## Conclusões

- A disciplina de Aprendizado de Máquina contém um conjunto de ferramentas e recursos úteis e poderosos para lidar com dados, de maneira a extrair informações dos dados e auxiliar na tomada de decisões estratégicas.
- Mais importante que o aprendizado em si é o tratamento dado aos dados, desde sua coleta até sua preparação antes de ocorrer o aprendizado. Ainda, fenômenos que ocorrem durante o aprendizado devem ser observados.
- O aprendizado não acaba quando um modelo é ajustado aos dados, ainda é preciso avaliar os modelos quanto a métricas, bem como compará-los com outros modelos (AM não é música pra gente só apertar *play!*)

# Outros tópicos

## Para onde ir agora?

- Alguns links úteis para prosseguir nos estudos de AM:
  - Programa de Cursos Integrados Aprendizagem Automática, lecionado pelo professor Andrew Ng, da Universidade de Stanford, e outros: <https://www.coursera.org/specializations/machine-learning-introduction>
  - [Google Machine Learning Crash Course](#)
  - Anotações de Machine Learning de Chris Albon: <https://chrisalbon.com>
  - Towards Data Science;
  - Machine Learning Mastery;

# Outros tópicos


## Para onde ir agora?

- Algumas redes sociais interessantes:
  - Normalized Nerd <https://www.youtube.com/@NormalizedNerd>
  - Programação Dinâmica (Anteriormente Python Café) <https://www.youtube.com/@pgdinamica>
  - Stat Quest With Josh Starmer <https://www.youtube.com/@statquest>
  - 3Blue1Brown <https://www.youtube.com/@3blue1brown>
  - Visually Explained <https://www.youtube.com/@VisuallyExplained>
  - Universo Programado <https://www.youtube.com/@UniversoProgramado>
  - Curso em Vídeo <https://www.youtube.com/@CursoemVideo>

# Referências

## Referências


FACELI, Katti et al. Inteligência artificial: uma abordagem de aprendizado de máquina. Segunda Edição. Rio de Janeiro: LTC. 2021



# Referências

## Referências


BRUCE, Andrew; BRUCE, Peter. **Estatística Prática para Cientistas de Dados**. Alta Books, 2019.



# Referências

## Referências


RUSSELL, Stuart; NORVIG, Peter. Inteligência Artificial: uma abordagem moderna. Editora LTC, 2013.



# Referências

## Referências


JAMES, Gareth et al. **An introduction to statistical learning.**  
New York: springer, 2013.



# Referências - Recomendações

## Recomendações

BHARGAVA, Aditya. **Grokking Algorithms: An illustrated guide for programmers and other curious people.** Simon and Schuster, 2016.



# Encerramento

## Algumas dicas bem úteis

- Crie o hábito de consultar a documentação oficial da sua linguagem, *framework* ou biblioteca, além de pesquisar na sua *Search Engine* favorita.
- Não foque muito na limpeza do código de primeira, essas coisas se aprendem com experiência. Tá tudo bem “fazer feio”.
- Tenha para si um projeto pessoal, por mais “bobo”, “pouco original” e “trivial” que seja (mas evite “copiar” também, claro). Tome muito cuidado com o tanto de cursos que acumula e não caia na armadilha de pensar que não está “pronto(a) ainda” porque não estudou “aquele aquele aquele” conteúdo.
- Quando possível, estude os fundamentos por trás do seu programa.

# Encerramento

## Obrigado pela audiência!

- Email: [victorcdefaria@gmail.com](mailto:victorcdefaria@gmail.com)
- GitHub: <https://github.com/VictorCastroDeFaria/>
- LinkedIn: <https://www.linkedin.com/in/victor-castro-651762156/>